第4回

Matplotlibの実習

機械学習を実施するにあたり「データを作成（調整）」することは非常に重要です。 予測の精度にも関わります。機械学習を始める前にデータを調整することを **前処理** と言います。データの前処理は、データ分析の全行程のうち約8割を占める重要な工程です。

ここではデータの前処理について理解いただくための課題を用意しました。この課題ではkaggleのcompetitionで使用されたデータを用いてデータの前処理方法を確認します。

各列の詳細は下記サイトをご参照ください。 https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data (https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data)

各セルに入っているコメントの下に、実行するコードを記入してください。わからない場合は、各種ライブラリの公式ドキュメントを参照しましょう。

1. 必要なモジュールの読み込み

In [1]:

```
import matplotlib
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

matplotlib.style.use('ggplot')

%matplotlib inline
```

2. データの読み込み

CSVファイル"kaggle_housing_price.csv"を読み込み、内容を確認します。

In [2]:

```
# データを変数datasetに読み込む
housing_data = pd.read_csv("kaggle_housing_price.csv")
```

In [3]:

```
# データを最初の5行だけ表示
housing_data.head(5)
```

Out[3]:

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Ut
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	A
1	2	20	RL	80.0	9600	Pave	NaN	Reg	Lvl	A
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	A
3	4	70	RL	60.0	9550	Pave	NaN	IR1	Lvl	A
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	A

5 rows × 81 columns

演習：データを最後の5行だけ表示してください

In [4]:

```
# データを最後の5行だけ表示
housing_data.tail()

# データを最後の１０行だけ表示
housing_data.tail(10)
```

Out[4]:

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandConto
1450	1451	90	RL	60.0	9000	Pave	NaN	Reg	L
1451	1452	20	RL	78.0	9262	Pave	NaN	Reg	L
1452	1453	180	RM	35.0	3675	Pave	NaN	Reg	L
1453	1454	20	RL	90.0	17217	Pave	NaN	Reg	L
1454	1455	20	FV	62.0	7500	Pave	Pave	Reg	L
1455	1456	60	RL	62.0	7917	Pave	NaN	Reg	L
1456	1457	20	RL	85.0	13175	Pave	NaN	Reg	L
1457	1458	70	RL	66.0	9042	Pave	NaN	Reg	L
1458	1459	20	RL	68.0	9717	Pave	NaN	Reg	L
1459	1460	20	RL	75.0	9937	Pave	NaN	Reg	L

10 rows × 81 columns

DataFrameの shape プロパティで全データの行数と列数を取得できます。

参照：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.shape.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.shape.html)

In [5]:

```
# データの行数、列数を表示
housing_data.shape
```

Out[5]:

(1460, 81)

3. 要約統計量を出力する

データ数、平均や中央値、標準偏差などの統計量を確認し、データへの理解を深めます。

なお、DataFrameの describe() を使うと、様々な統計量の情報を要約として表示してくれます。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.describe.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.describe.html)

In [6]:

```
# 要約統計量を表示
housing_data.describe()
```

Out[6]:

	Id	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	Ye
count	1460.000000	1460.000000	1201.000000	1460.000000	1460.000000	1460.000000	1460.(
mean	730.500000	56.897260	70.049958	10516.828082	6.099315	5.575342	1971.:
std	421.610009	42.300571	24.284752	9981.264932	1.382997	1.112799	30.:
min	1.000000	20.000000	21.000000	1300.000000	1.000000	1.000000	1872.(
25%	365.750000	20.000000	59.000000	7553.500000	5.000000	5.000000	1954.(
50%	730.500000	50.000000	69.000000	9478.500000	6.000000	5.000000	1973.(
75%	1095.250000	70.000000	80.000000	11601.500000	7.000000	6.000000	2000.(
max	1460.000000	190.000000	313.000000	215245.000000	10.000000	9.000000	2010.(

8 rows × 38 columns

4. 基本的なデータの操作

データの抽出・列の分割について学びます。

インデックスを用いた行の指定

In [11]:

```
# インデックス番号0~10の行を抽出
housing_data.iloc[0:10,0:5]
```

Out[11]:

	Id	MSSubClass	MSZoning	LotFrontage	LotArea
0	1	60	RL	65.0	8450
1	2	20	RL	80.0	9600
2	3	60	RL	68.0	11250
3	4	70	RL	60.0	9550
4	5	60	RL	84.0	14260
5	6	50	RL	85.0	14115
6	7	20	RL	75.0	10084
7	8	60	RL	NaN	10382
8	9	50	RM	51.0	6120
9	10	190	RL	50.0	7420

In [12]:

```
# "SalePrice"と"LotArea"の列を抽出し、最初の10行だけ表示
housing_data.loc[0:9:, ["SalePrice","LotArea"]]
```

Out[12]:

	SalePrice	LotArea
0	208500	8450
1	181500	9600
2	223500	11250
3	140000	9550
4	250000	14260
5	143000	14115
6	307000	10084
7	200000	10382
8	129900	6120
9	118000	7420

カラム間の演算

PandasのDataFrameでは、列同士の四則演算、ならびに新しい列を追加することができます。

たとえば、 df というDataFrameの変数があり、中に a , b というカラムが存在するとき、 df['c'] = df['a'] + df['b'] と記述することで、a列とb列の加算結果を c という新しい列として df に追加してくれます。

In [13]:

```
# "1stFlrSF"と"2ndFlrSF"を合計した"FlrSF_total"を新たな列としてdatasetに加える
df=pd.DataFrame(housing_data)
df['FlrSF_total'] = df['1stFlrSF'] + df['2ndFlrSF']
```

In [14]:

```
# datasetからiloc関数を使用して"1stFlrSF"と"2ndFlrSF"、"FlrSF_total"を先頭から5行分表示し、正しく追加
df.loc[0:4, ["1stFlrSF", "2ndFlrSF","FlrSF_total"]]
```

Out[14]:

	1stFlrSF	2ndFlrSF	FlrSF_total
0	856	854	1710
1	1262	0	1262
2	920	866	1786
3	961	756	1717
4	1145	1053	2198

ダミー変数の作成

列 SaleType は WD , New , COD など、合わせて9種類の値しかありません。このようなデータをもつ列は一般的に **カテゴリ変数** と呼んでいます（Lesson6以降で改めて説明します）。カテゴリ変数のデータは、**ダミー変数** にしてあげましょう。たとえば SaleType ですと、

- SaleType_WD : SaleType のデータが WD なら1、それ以外の場合は0が入る列
- SaleType_New : SaleType のデータが New なら1、それ以外の場合は0が入る列
- SaleType_COD : SaleType のデータが COD なら1、それ以外の場合は0が入る列

（以下省略）

このようにして、 SaleType のデータの種類数に合わせて9個の新しい列を作成します。この9個の列には、1つが 1 で、残りは全て 0 が入っています。これがダミー変数です。

ダミー変数化するのに最も楽な方法は、Pandasの get_dummies() を使う方法です。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.get_dummies.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.get_dummies.html)

In [15]:

```
# 列'SaleType'をダミー変数に展開したものを変数 dataset に上書きします。
dataset=pd.get_dummies(df['SaleType'])
print(dataset)
```

```
      COD  CWD  Con  ConLD  ConLI  ConLw  New  Oth  WD
0       0    0    0      0      0      0    0    0   1
1       0    0    0      0      0      0    0    0   1
2       0    0    0      0      0      0    0    0   1
3       0    0    0      0      0      0    0    0   1
4       0    0    0      0      0      0    0    0   1
...   ...  ...  ...    ...    ...    ...  ...  ...  ..
1455    0    0    0      0      0      0    0    0   1
1456    0    0    0      0      0      0    0    0   1
1457    0    0    0      0      0      0    0    0   1
1458    0    0    0      0      0      0    0    0   1
1459    0    0    0      0      0      0    0    0   1

[1460 rows x 9 columns]
```

In [16]:

```
# ダミー変数が作成されていることを確認します　(datasetの最初の5行だけ出力)
dataset.head()
```

Out[16]:

	COD	CWD	Con	ConLD	ConLI	ConLw	New	Oth	WD
0	0	0	0	0	0	0	0	0	1
1	0	0	0	0	0	0	0	0	1
2	0	0	0	0	0	0	0	0	1
3	0	0	0	0	0	0	0	0	1
4	0	0	0	0	0	0	0	0	1

フィルタリング

特定の条件の行のみ抽出することができます。そのために、DataFrameの query() を使います。括弧の中に条件式を記述してください。

たとえば、 LotArea が 15000以上 という条件にするなら、 dataset.query('LotArea >= 15000') です。最後に .head() を追記すれば、今までどおり5件だけの取得になります。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.query.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.query.html)

In [17]:

```
# 'YearBuilt'が2000以降の物件のみを抽出し、最初の5件のみ表示
dataset=pd.DataFrame(housing_data)
dataset=dataset.query('YearBuilt>=2000')
#print(dataset['YearBuilt'])
dataset.head()
```

Out[17]:

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	U
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	
6	7	20	RL	75.0	10084	Pave	NaN	Reg	Lvl	
11	12	60	RL	85.0	11924	Pave	NaN	IR1	Lvl	

5 rows × 82 columns

dataset.query('LotArea >= 15000 and MSSubClass >= 50') のように複数の条件を指定することも可能です。

In [18]:

```
# 'YearBuilt'が2000以降、'GarageCars'が2以上の物件を抽出
dataset=pd.DataFrame(housing_data)
dataset=dataset.query('YearBuilt >= 2000 and GarageCars >= 2')
#print(dataset['YearBuilt'],dataset['GarageCars'])
dataset.head()
```

Out[18]:

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	U
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	
6	7	20	RL	75.0	10084	Pave	NaN	Reg	Lvl	
11	12	60	RL	85.0	11924	Pave	NaN	IR1	Lvl	

5 rows × 82 columns

5. データの可視化

データを理解するには要約統計量や抽出したデータを確認するだけでは不十分であり、可視化が必要です。

ヒストグラム

連続変数の分布を確認する際に有効です。DataFrameの hist() が使えます。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.hist.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.hist.html)

In [19]:

```
# datasetの'SalePrice'をヒストグラムで表示
housing_data = pd.read_csv("kaggle_housing_price.csv")
df=pd.DataFrame(housing_data)
df.hist('SalePrice')
```

Out[19]:

```
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x0000021A9D9E6160>]],
      dtype=object)
```

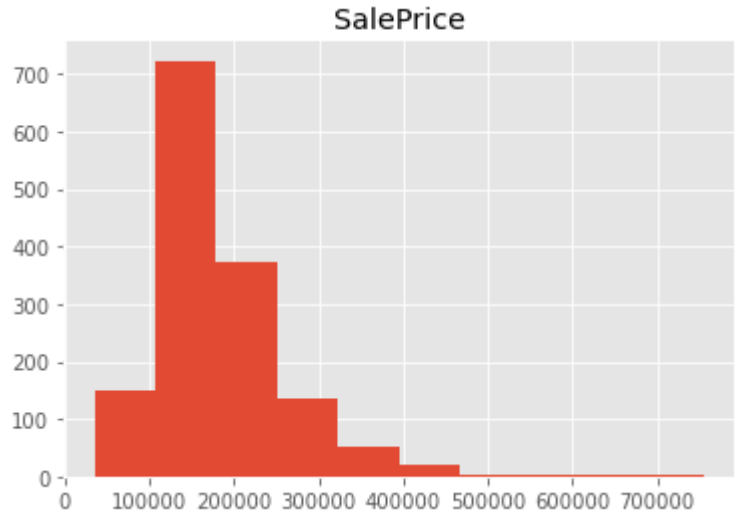

散布図

2つの変数の関係性を確認する際に有効です。DataFrameの plot() が使えます。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.plot.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.plot.html)

In [20]:

```
# datasetの'LotArea'と'SalePrice'を散布図で表示
df=pd.DataFrame(housing_data)
df.plot(kind='scatter', x='LotArea', y='SalePrice')
```

Out[20]:

<matplotlib.axes._subplots.AxesSubplot at 0x21a9e158e20>

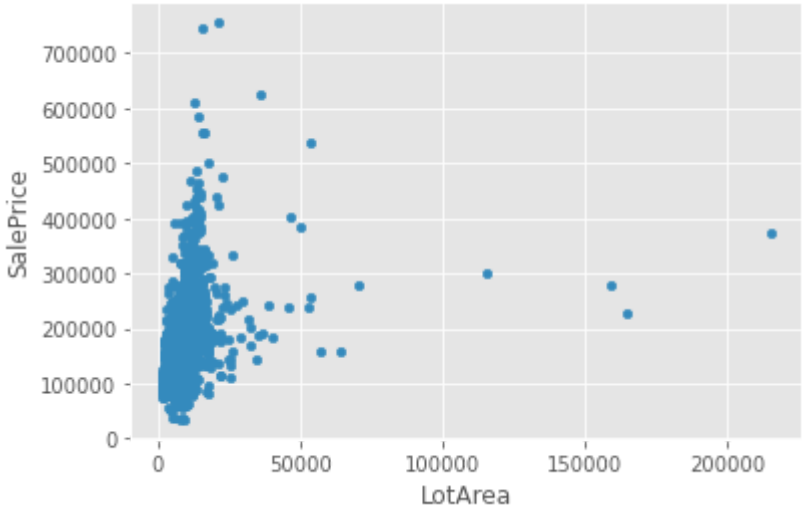

棒グラフ

大小や増減を比較する際に有効です。DataFrameの plot.bar() が使えます。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.plot.bar.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.plot.bar.html)

In [21]:

```
#'SalePrice'のSaleCondition毎の平均を変数　price_by_conditionに格納
df=pd.DataFrame(housing_data)
grouped = df.groupby('SaleCondition')

price_by_condition=grouped.mean().SalePrice

df=pd.DataFrame(price_by_condition)

# price_by_conditionが持つ、棒グラフを表示する命令を実行
df.plot.bar()
```

Out[21]:

<matplotlib.axes._subplots.AxesSubplot at 0x21a9f184d60>

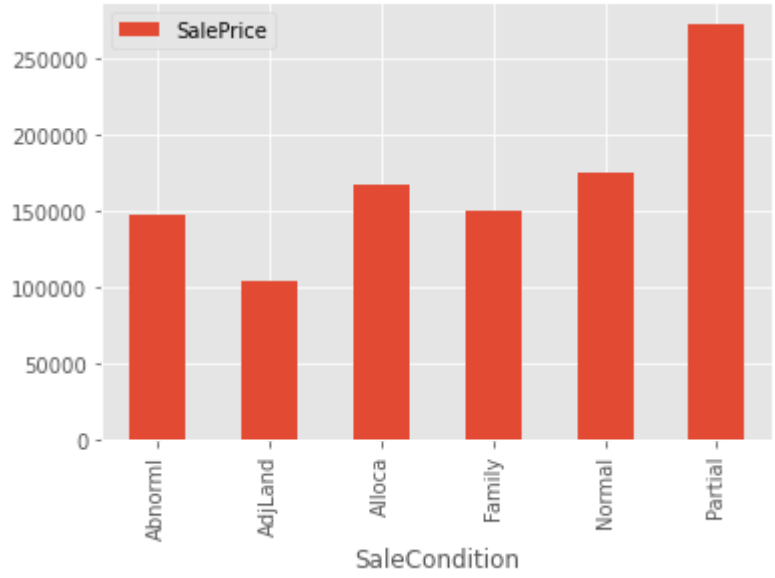

箱ヒゲ図 (Boxplot)

複数の変数の分布を比較する際に有効です。 （棒グラフでは平均の比較はできますが、分布全体の比較はできません)

DataFrameの boxplot() が使えます。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.boxplot.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.DataFrame.boxplot.html)

In [22]:

```
h_data=housing_data.loc[0::,["SaleCondition","SalePrice"]]
df=pd.DataFrame(h_data)

# datasetの'SaleCondition'ごとに'SalePrice'をboxplotで表示
df.boxplot(by='SaleCondition')
```

Out[22]:

<matplotlib.axes._subplots.AxesSubplot at 0x21a9f1f3a00>

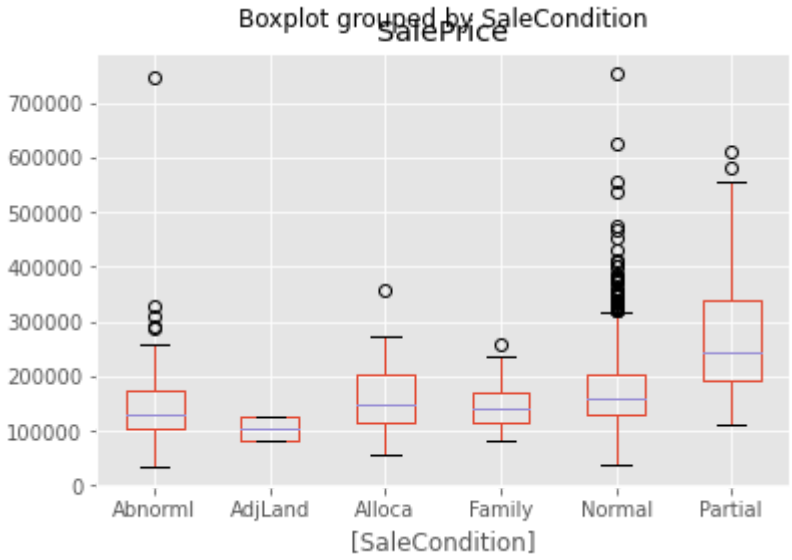

6. 欠損値の確認

通常の集めたデータは、一部のデータが欠けていることがほとんどです。

欠けているデータを **欠損値** といいます。データに欠損値があると、演算でエラーが起きる場合があります。

欠損値の扱いは欠損が発生した原因により異なります。基本的には、精度に影響しないようなデータで埋めます。一例としては 0 、平均値や中央値などです。

ある列が欠損値を持っているかどうかは Pandas の isnull() でわかります。
pd.isnull(dataset['LotFrontage']) のように記述します。また、 .sum() をつなげることで、その列で欠損値を持つ行数がわかります。

参考：http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.isnull.html (http://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.isnull.html)

In [23]:

```
# 列ごとに欠損値の有無を確認
df=pd.DataFrame(housing_data)
print(df.isnull().sum())
```

```
Id                0
MSSubClass        0
MSZoning          0
LotFrontage     259
LotArea           0
                 ...
MoSold            0
YrSold            0
SaleType          0
SaleCondition     0
SalePrice         0
Length: 81, dtype: int64
```

課題1　　'YearBuilt'が2005年以降、'GarageCars'が2以上の物件を抽出してください

In [34]:

```
# 'YearBuilt'が2005以降、'GarageCars'が2以上の物件を抽出
dataset=pd.DataFrame(housing_data)
dataset=dataset.query('YearBuilt >= 2005 and GarageCars >= 2')
print(dataset['YearBuilt'],dataset['GarageCars'])
#dataset.head()
```

```
1324    3
1330    3
1344    2
1347    3
1361    2
1363    2
1364    2
1374    3
1375    3
1379    2
1388    3
1394    3
1395    3
1402    2
1403    3
1413    2
1415    3
1430    2
1437    3
1442    3
```

課題2　datasetの'YearBuilt'をヒストグラムで表示してください

In [24]:

```
# datasetの'YearBuilt'をヒストグラムで表示
housing_data = pd.read_csv("kaggle_housing_price.csv")
df=pd.DataFrame(housing_data)
df.hist('YearBuilt')
```

Out[24]:

```
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x0000021A9F2F3A90>]],
      dtype=object)
```

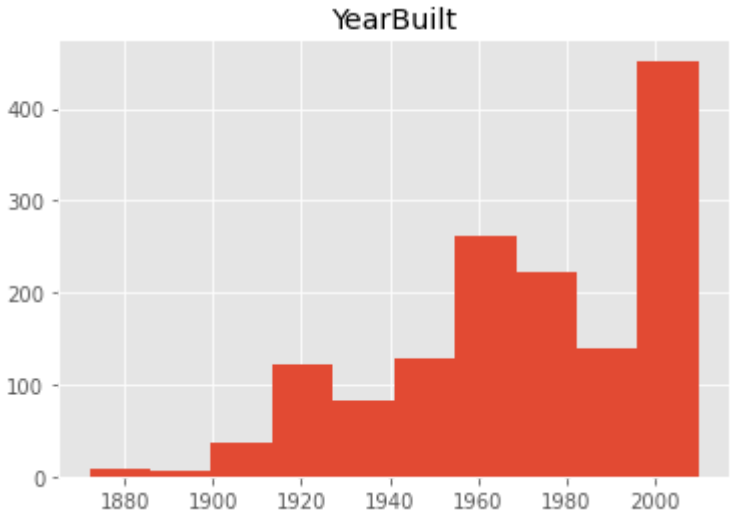

課題3　datasetの'LotFrontage'と'SalePrice'の関係を散布図で表示してください

In [25]:

```
# datasetの'LotFrontage'と'SalePrice'を散布図で表示
df=pd.DataFrame(housing_data)
df.plot(kind='scatter', x='LotFrontage', y='SalePrice')
```

Out[25]:

<matplotlib.axes._subplots.AxesSubplot at 0x21a9f336bb0>

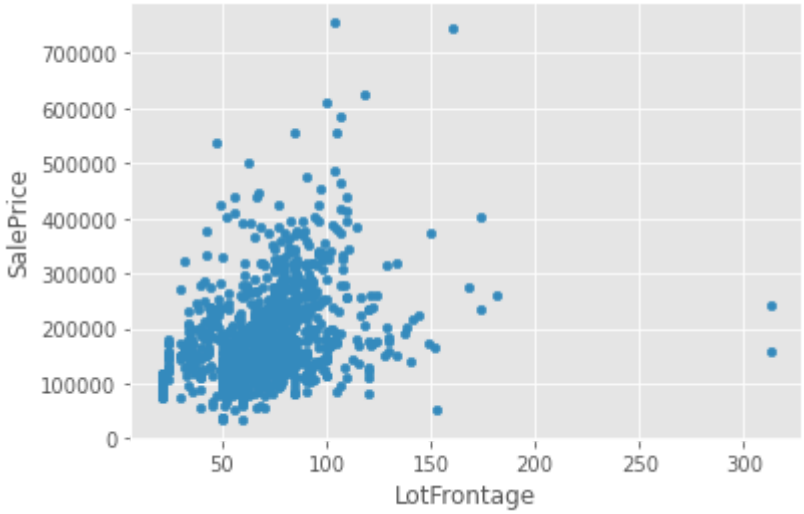

課題４　datasetの'SaleType'ごとに'SalePrice'を箱ひげ図で表示してください

In [26]:

```
h_data=housing_data.loc[0::,["SaleType","SalePrice"]]
df=pd.DataFrame(h_data)

# datasetの'SaleCondition'ごとに'SalePrice'をboxplotで表示
df.boxplot(by='SaleType')
```

Out[26]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x21a9e11efa0>
```

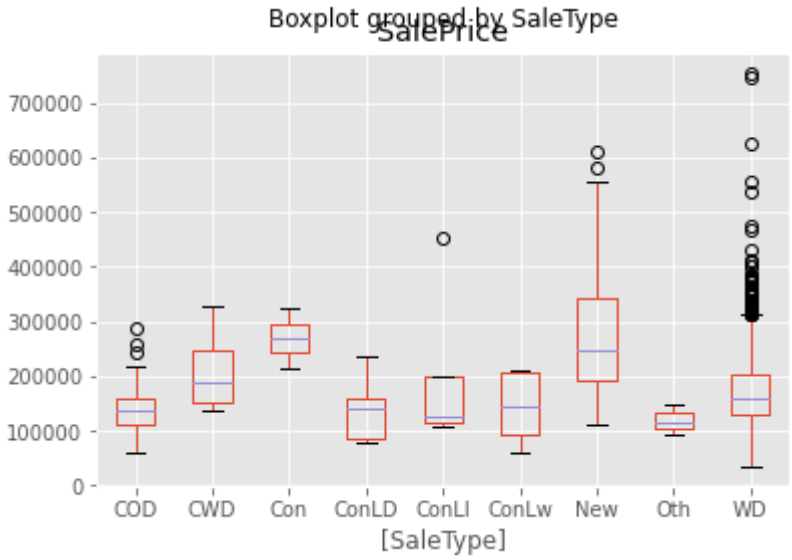

In [ ]: